



APRESENTAÇÃO EXECUTIVA

Quem vai pagar a fatura? Como usar dados para concentrar a análise de crédito onde está o risco

Um modelo de aprendizado de máquina que ordena os pedidos de cartão de crédito do mais ao menos arriscado.

Cada cartão aprovado para quem não paga vira prejuízo, e analisar todos os pedidos com o mesmo cuidado é caro e lento

1,7%

dos clientes com histórico deixaram de pagar pelo menos **duas faturas seguidas**. É uma agulha no palheiro: 616 casos em 36.457 clientes.

98,3%

de acerto teria quem dissesse “**todo mundo é bom pagador**”, sem encontrar um único caso de risco. Taxa de acerto não mede a qualidade aqui.

A pergunta que o projeto responde

Com as informações disponíveis de cada cliente, dá para **ordenar os pedidos pelo risco** e mandar para análise humana primeiro os que mais precisam dela?

Duas fontes: quem é o cliente e como ele pagou mês a mês

Cadastro · 438 mil solicitantes

Renda, idade, tempo de emprego, escolaridade, estado civil, moradia, patrimônio e família.

Histórico · 1 milhão de registros mensais

Situação de pagamento de cada cliente em cada mês, com até 5 anos de histórico por pessoa.

Quem é “mau pagador”?


A base não diz quem foi aprovado ou recusado.

Definimos como mau pagador quem teve **atraso de 60 dias ou mais**, ou seja, deixou de pagar duas faturas seguidas.

Atrasos curtos (até 29 dias) são o comportamento de 3 em cada 4 clientes e não indicam risco real. O corte de 60 dias separa o esquecimento da dificuldade financeira.

36.457 clientes aparecem nas duas fontes e formam a base do estudo.

Não existe um perfil óbvio de mau pagador: as diferenças entre grupos são pequenas



- A taxa de maus pagadores varia só entre **1,2% e 2,9%** entre os perfis.
- Nenhuma característica isolada, nem mesmo a renda, separa bons de maus pagadores.
- O sinal está na **combinação** de várias características. É esse o trabalho de um modelo.

Quatro armadilhas nos dados foram encontradas e tratadas antes de qualquer modelo

Aposentados com “1.000 anos de emprego”

17% dos cadastros usam um código especial no tempo de emprego. Ele foi reconhecido como “sem vínculo” em vez de ser lido como número.

Ocupação em branco em 31% dos casos

A maioria é de aposentados. O campo virou “não informado”, em vez de ser preenchido com um palpite.


Clientes duplicados com dados diferentes

47 identificadores repetidos com renda e idade diferentes. Mantivemos um registro por cliente.

A “resposta disfarçada”

Uma informação reproduzia a própria definição de mau pagador e dava um falso acerto de 100%. Foi identificada e removida.


Quatro abordagens comparadas nas mesmas condições. A vencedora foi o XGBoost



Nota de 0,5 a 1,0 para a capacidade de colocar os maus pagadores no topo da lista: 0,5 equivale a sorteio e 1,0 seria perfeito. Medida em clientes que o modelo nunca viu.

- **XGBoost** teve a melhor nota nos dois testes: **0,83** no treino com validação e **0,82** em clientes novos. É estável, não “decorou” os dados.
- Todos os modelos superam com folga o sorteio. Existe sinal real nos dados.
- O desequilíbrio (1,7% de maus pagadores) foi compensado no treino, dando mais peso aos casos raros.

Revisando só os 20% de pedidos mais arriscados, a equipe encontra 7 em cada 10 maus pagadores




69%

dos maus pagadores ficam entre os 20% de pedidos que o modelo aponta como mais arriscados. Um sorteio encontraria 20%.

50%

já aparecem nos 10% mais arriscados, cinco vezes mais que o acaso.

O histórico de relacionamento com o banco diz mais sobre o risco do que o cadastro



- **Mais meses quitando o saldo e uso moderado do crédito** indicam menor risco.
- **Mais tempo de histórico** aumenta o risco estimado, em parte porque há mais meses em que um atraso pode acontecer.
- No cadastro, **idade e tempo de emprego maiores** indicam menor risco.

Dois métodos independentes de explicação chegaram à mesma ordem de importância.

O modelo é uma ferramenta de priorização, não um juiz automático

15 : 1

Se o modelo recusasse sozinho, seriam negados cerca de **15 bons pagadores para cada mau pagador** evitado. A decisão final deve ser humana.

0,82 → 0,66

A nota cai para **clientes sem histórico** com o banco. Para quem chega pela primeira vez, é preciso complementar com birôs de crédito externos.

Equidade

O gênero influencia a previsão. Antes de qualquer uso real, é preciso uma auditoria de equidade e uma validação jurídica, avaliando a retirada dessa informação.

Próximos passos para levar o modelo à operação

- **Piloto de priorização:** ordenar a fila de análise pelo risco estimado e medir quantos maus pagadores a equipe passa a encontrar.
- **Definir o ponto de corte com a área de risco,** a partir do custo real de um calote e de um bom cliente perdido.
- **Auditoria de equidade** antes de qualquer uso em decisão real.
- **Integrar birôs de crédito** para os solicitantes sem histórico.
- **Reavaliar periodicamente** com dados novos, separando no tempo o período de observação e o de resultado.

“Menos tempo gasto nos pedidos seguros, mais atenção onde o risco está.”