

TECH CHALLENGE · FASE 2 · POSTECH FIAP


# Quem vai pagar a fatura?

Machine Learning para concentrar a análise de crédito onde está o risco

**Grupo 12 · Turma 12DTAT**

Anderson Leão da Silva · Jessika Midory Fukuyama

Leticia Nery Barbosa Dias · Pricilla Teixeira da Silva



*1 em cada 60 clientes deixou de pagar duas faturas seguidas*

# Achar o mau pagador é procurar agulha no palheiro

1,7%

dos clientes atrasaram 60 dias ou mais  
(616 de 36.457)

98,3%

de acerto para quem disser "todos são  
bons", sem achar nenhum caso de risco

**Por isso a taxa de acerto engana.** Medimos o modelo pela capacidade de colocar os maus pagadores no topo da lista.



## A pergunta do projeto

Com o que sabemos de cada cliente, dá para ordenar os pedidos pelo risco e mandar para análise humana primeiro os que mais precisam?

# Duas fontes de dados e uma regra clara de risco



**438 mil**

**solicitantes no cadastro**

renda, idade, emprego, família, moradia



**1,05 milhão**

**registros mensais de pagamento**

até 5 anos de histórico por cliente



**36.457**

**clientes nas duas fontes**

que são, na verdade, 9.728 pessoas

**Quem é "mau pagador"? Pior atraso de cada cliente no histórico:**

Sem empréstimo ou quitado (X, C)


Atraso de 1 a 29 dias (0)

30 a 59 dias (1)

**60 dias ou mais (2 a 5)**

*Mau pagador = deixou de pagar duas faturas seguidas. Atrasos curtos são comuns (3 em cada 4 clientes) e não indicam risco real.*

# Não existe um perfil óbvio de mau pagador



## 1,2% a 2,9%

é toda a variação entre os perfis. A média geral é 1,7%.

Nenhuma característica isolada, nem a renda, separa bons de maus pagadores.

**O sinal está na combinação de várias delas. É isso que um modelo faz bem.**

# Quatro armadilhas nos dados, todas tratadas



## "1.000 anos de emprego"

17% dos cadastros usam um código especial no tempo de emprego. Virou o indicador "sem vínculo", e não um número.



## Ocupação em branco em 31%

A maioria é de aposentados. Virou a categoria "não informado", sem preencher com palpite.



## A mesma pessoa com vários IDs


36.457 contas são de só 9.728 pessoas. Treino e teste foram separados por pessoa: o modelo é testado em quem nunca viu.



## A "resposta disfarçada"

Uma variável repetia a própria definição de mau pagador e dava um falso acerto de 100%. Foi encontrada e removida.

# XGBoost foi o melhor de quatro modelos



**0,80**

nota em clientes novos (faixa provável de 0,76 a 0,83)

**0,80 ± 0,03**


na validação cruzada: estável, não "decorou" os dados

**0,79**

Regressão Logística: empate técnico, mais simples de explicar

*Nota de 0,5 (sorteio) a 1,0 (perfeito) para pôr os maus pagadores no topo da lista (ROC-AUC), medida em pessoas que o modelo nunca viu*

# Revisar 20% dos pedidos acha 64% dos maus pagadores




*Fatia de pedidos revisados, dos mais arriscados para os menos · % dos maus pagadores encontrados*

3,2x

mais maus pagadores encontrados  
que por sorteio, com o mesmo  
esforço

Com só 10% dos pedidos, já encontra  
40%: quatro vezes o acaso.

# O histórico com o banco pesa mais que o cadastro



■ histórico com o banco ■ cadastro · peso relativo (o mais importante = 100)



Meses quitando o saldo e uso moderado do crédito indicam menor risco



Mais tempo de histórico eleva o risco estimado: há mais meses em que um atraso pode acontecer



No cadastro, emprego e renda maiores indicam menor risco, mas pesam pouco



Dois métodos de explicação diferentes chegaram à mesma ordem

# Uma ferramenta de priorização, não um juiz automático

## 17 : 1

Se recusasse sozinho, o modelo negaria cerca de 17 bons pagadores para cada mau pagador evitado. A decisão final deve ser humana.

## 0,80 → 0,59

Só com o cadastro, a nota cai para perto do sorteio. O modelo serve para quem já é cliente; para quem chega agora, usar birôs de crédito.

## Equidade

O gênero influencia a previsão. Antes de qualquer uso real: auditoria de equidade e validação jurídica.

### Como usar:



Pedido chega



Modelo ordena pelo risco



Analista decide

# Conclusões e próximos passos

## O que concluímos



### O modelo funciona

XGBoost com nota 0,80 em clientes nunca vistos, contra 0,50 do sorteio



### Gera valor na prática

Revisando 20% dos pedidos, a equipe acha 64% dos maus pagadores: 3,2 vezes o acaso



### Quem prevê é o histórico

Só com o cadastro, a nota cai para 0,59. O modelo vale para quem já é cliente

## Próximos passos

1

Piloto: ordenar a fila de análise pelo risco e medir o ganho

2

Definir o ponto de corte com a área de risco e auditar a equidade

3

Usar birôs de crédito para quem ainda não tem histórico

**Obrigado! · Grupo 12**