

Roteiro da apresentação em vídeo

Tech Challenge Fase 2 · Grupo 12 · Turma 12DTAT · acompanha `apresentacao_video_grupo12.pptx`

Duração estimada: de 4min20s a 4min55s (642 palavras; 4min20s a 150 palavras por minuto, 4min55s a 130). O limite é de 5 minutos. Se passar, encurte primeiro os slides 4 e 8. A divisão de falas é uma sugestão: cada integrante apresenta 2 ou 3 slides seguidos, e todos aparecem no final. O mesmo texto está nas **anotações do orador** de cada slide no PowerPoint.

Integrante	Slides
Anderson	1, 2 e 9
Jessika	3 e 4
Leticia	5 e 6
Pricilla	7 e 8
Todos	10 (conclusões e encerramento)



Slide 1 · Capa · Quem vai pagar a fatura? **0:00–0:20 · Anderson**

“Olá! Nós somos o Grupo 12, da turma 12DTAT: Anderson, Jessika, Leticia e Pricilla. Neste vídeo vamos mostrar como usamos Machine Learning para ajudar um banco a decidir onde concentrar a análise dos pedidos de cartão de crédito.”

Na tela: Apresente-se olhando para a câmera. Aponte os pontinhos: um deles, o amarelo, é o mau pagador.



Slide 2 · O problema **0:20–0:50 · Anderson**

“Todo cartão aprovado para quem não paga vira prejuízo, e analisar cada pedido com o mesmo cuidado é caro e lento. Na nossa base, só 1,7% dos clientes deixaram de pagar duas faturas seguidas. É uma agulha no palheiro. Por isso a taxa de acerto engana: quem dissesse que todo mundo é bom pagador acertaria 98% das vezes, sem encontrar um único caso de risco. Então a nossa pergunta foi: dá para ordenar os pedidos pelo risco e mandar primeiro para análise os que mais precisam?”


Na tela: Destaque os dois números grandes; termine lendo a pergunta do quadro escuro.



Slide 3 · Os dados **0:50–1:15 · Jessika**

“Usamos duas fontes: o cadastro de 438 mil solicitantes e mais de um milhão de registros mensais de pagamento. Juntando as duas, ficamos com 36 mil clientes. Como a base não diz quem foi aprovado, definimos como mau pagador quem atrasou 60 dias ou mais, ou seja, deixou de pagar duas faturas seguidas. Atrasos curtos são comuns, acontecem com três em cada quatro clientes, e não indicam risco real.”

Na tela: Percorra a faixa colorida da esquerda para a direita e pare no bloco vermelho.



Slide 4 · Sem perfil óbvio

1:15–1:40 · Jessica

“O primeiro achado da análise exploratória: não existe um perfil óbvio de mau pagador. Entre os grupos, a taxa varia só entre 1,2% e 2,9%. Nenhuma característica isolada resolve o problema. O sinal está na combinação de várias delas, e é isso que um modelo faz bem.”

Na tela: Mostre as barras vermelhas (acima da média) e as verdes (abaixo).




Slide 5 · Cuidados antes de modelar

1:40–2:20 · Leticia

“Antes de modelar, tratamos quatro armadilhas. Aposentados apareciam com um código que parecia mil anos de emprego; a ocupação estava em branco em 31% dos casos. As duas mais importantes estão em vermelho. Primeiro, a mesma pessoa aparecia com vários cadastros: as 36 mil contas são de menos de 10 mil pessoas. Por isso separamos treino e teste por pessoa, para testar o modelo em quem ele nunca viu. Segundo, uma variável era a própria resposta disfarçada e dava um falso acerto de 100%. Ela foi encontrada e removida.”

Na tela: Fale rápido dos dois cards verdes e dê ênfase aos dois vermelhos.




Slide 6 · A solução

2:20–2:55 · Leticia

“Comparamos quatro modelos nas mesmas condições. O vencedor foi o XGBoost, com nota 0,80, numa escala em que 0,5 é sorteio e 1 seria perfeito. Essa nota foi medida em pessoas que o modelo nunca tinha visto, e ficou estável na validação cruzada, ou seja, o modelo não decorou os dados. A Regressão Logística ficou praticamente empatada e é uma alternativa mais simples de explicar.”

Na tela: Aponte a barra do XGBoost e a do sorteio para mostrar a distância.



Slide 7 · O resultado na prática

2:55–3:30 · Pricilla

“Este é o resultado mais importante. Se a equipe revisar só os 20% de pedidos que o modelo aponta como mais arriscados, encontra 64% de todos os maus pagadores. Um sorteio encontraria 20%. São três vezes mais casos com o mesmo esforço. E com apenas 10% dos pedidos, já encontra 40%, quatro vezes o acaso.”

Na tela: Compare as duas barras do grupo top 20% e termine no 3,2x.



Slide 8 · O que mais pesa

3:30–3:55 · Pricilla

“O que mais pesa na previsão é o histórico com o banco, as barras verdes. Meses quitando o saldo e uso moderado do crédito indicam menor risco. No cadastro, tempo de emprego e renda maiores também indicam menor risco, mas pesam pouco.”

Na tela: Contraste as três barras verdes com as cinzas.

08 - LIMITES QUE PRECISAM SER RESPEITADOS

Uma ferramenta de priorização, não um juiz automático

17 : 1

Se recusasse sozinho, o modelo negaria cerca de 17 bons pagadores para cada mau pagador evitado. A decisão final deve ser humana.

0,80 → 0,59

Só com o cadastro, a nota cai para perto do sorteio. O modelo serve para quem já é cliente; para quem chega agora, usar bônus de crédito.

Equidade

O gênero influencia a previsão. Antes de qualquer uso real: auditoria de equidade e validação jurídica.

Como usar:

Pedido chega → Modelo ordena pelo risco → Analista decide

Slides 12 - Tech Challenge Fase 2 - Priorização de novos pagadores

Slide 9 · Limites

3:55–4:30 · Anderson

“O modelo tem limites claros. Se recusasse pedidos sozinho, negaria cerca de 17 bons pagadores para cada mau pagador evitado. Por isso a decisão final deve ser humana. Só com os dados do cadastro, a nota cai para 0,59, perto do sorteio: o modelo serve para quem já é cliente. E, como o gênero influencia a previsão, é necessária uma auditoria de equidade antes de qualquer uso real.”

Na tela: Um card por frase, da esquerda para a direita.

09 - CONCLUSÃO

Conclusões e próximos passos

O que concluímos

- O modelo funciona**
Indicou com nota 0,80 que clientes nunca vistos, contra 0,50 do sorteio
- Gera valor na prática**
Revisando 20% dos pedidos, a equipe achou 64% dos maus pagadores: 3,2 vezes o acaso
- Quem prevê é o histórico**
Só com o cadastro, a nota cai para 0,59. O modelo vale para quem já é cliente

Obrigado! · Grupo 12

Próximos passos

1. Piloto: ordenar a fila de análise pelo risco e medir o ganho
2. Definir o ponto de corte com a área de risco e auditar a equidade
3. Usar bônus de crédito para quem ainda não tem histórico

Slide 10 · Conclusões e próximos passos

4:30–4:55 · Todos

“Concluindo: o modelo funciona, com nota 0,80 em clientes que ele nunca viu. Gera valor na prática: revisando só 20% dos pedidos, a equipe encontra 64% dos maus pagadores. E mostra que o que prevê o risco é o histórico com o banco, não o cadastro. Por isso recomendamos um piloto: ordenar a fila de análise pelo risco, definir o ponto de corte com a área de risco, auditar a equidade e usar bônus de crédito para quem ainda não tem histórico. Obrigado!”

Na tela: Uma conclusão por frase (lado esquerdo), depois os passos (lado direito). Se possível, todos aparecem na câmera para o "Obrigado".

Dicas de gravação

- No PowerPoint: **Apresentação de Slides → Gravar**. Ele grava voz e câmera slide a slide, mostra as anotações para quem fala e permite regravar só um slide. Depois, **Arquivo → Exportar → Criar um Vídeo (MP4)**.
- Alternativa: chamada no Google Meet ou Teams gravada, com uma pessoa compartilhando a tela e cada integrante falando na sua vez.
- Pelo menos um integrante precisa aparecer na câmera ou narrar. Fale olhando para a câmera, não para o texto.
- Ensaie uma vez cronometrando. Confira a duração final: **no máximo 5 minutos**.
- Publique no YouTube como **não listado** e teste o link numa janela anônima antes de mandar.